

Inteligencia Artificial

Estudiante Daniela Aldaz Contreras
 Catedrático Dr. Carlos Ignacio Hernández Castellanos
 Ayudante Alberto Alonso

1 Implementación

1.1 Modelo de redes bayesianas

Las redes bayesianas son una representación gráfica de dependencias para razonamiento probabilística, donde los nodos representan variables aleatorias y los arcos representan relaciones de dependencia directa entre variables.

La topología o estructura de la red nos da información sobre las dependencias probabilísticas entre las variables. La red también representa las independencias condicionales de una variable (o conjunto de variables) dadas otras variables. Una red bayesiana representa en forma gráfica las dependencias e independencias entre las variables aleatorias, en particular las independencias condicionales (Sucar, 2024).

Para la representación de las redes bayesianas, se hace uso de un diccionario donde las llaves representan los nodos y los valores las aristas dirigidas.

```

1 insurance_dirigida = {
2
3     #age and mileage son nodos independientes
4     'age': {'socio_econ', 'risk_aversion', 'good_student', 'senior_train', 'driving_skill', '
med_cost'},
5     'socio_econ': {'anti_theft', 'home_base', 'vehicle_year', 'other_car', 'make_model', '
risk_aversion', 'good_student'},
6     'risk_aversion': {'anti_theft', 'home_base', 'vehicle_year', 'make_model', 'driv_quality', '
driv_hist', 'senior_train'},
7     'good_student': {},
8     'senior_train': {'driving_skill'},
9     'driving_skill': {'driv_hist', 'driv_quality'},
10    'med_cost': {},
11    'anti_theft': {'theft'},
12    'home_base': {'theft'},
13    'vehicle_year': {'car_value', 'rugged_auto', 'antilock', 'airbag'},
14    'other_car': {},
15    'make_model': {'car_value', 'rugged_auto', 'antilock', 'airbag'},
16    'driv_quality': {'accident'},
17    'driv_hist': {},
18
19    'theft': {'this_car_cost'},
20    'car_value': {'theft', 'this_car_cost'},
21    'rugged_auto': {'this_car_dam', 'other_car_cost', 'cushioning'},
22    'antilock': {'accident'},
23    'airbag': {'cushioning'},
24    'this_car_cost': {'propcost'},
25    'this_car_dam': {'this_car_cost'},
26    'other_car_cost': {'propcost'},
27    'cushioning': {'med_cost'},
28    'accident': {'this_car_dam', 'other_car_cost', 'ili_cost', 'med_cost'},
29    'propcost': {},
30    'ili_cost': {},
31
32    'mileage': {'car_value', 'accident'},
33 }
```

Para su representación en forma de gráfico empleando la librería Networkx.

```

1 import networkx as nx
2 import matplotlib.pyplot as plt
3
4 G = nx.DiGraph()
5
6 nodes = []
```

```

7   for node in insurance_dirigida:
8       G.add_node(node)
9       for edge in insurance_dirigida[node]:
10          G.add_edge(node, edge)
11          nodes.append(node)
12   try:
13       # Crea la malla para colocar los nodos de la red
14       pos = nx.nx_agraph.graphviz_layout(G, prog='dot')
15   except:
16       # layout por defecto
17       pos = nx.spring_layout(G, k=1, seed=42)
18
19   #Tamano de la figura
20   plt.figure(figsize=(12, 10))
21
22   nx.draw_networkx_nodes(G, pos, node_color='skyblue', node_size=2000, alpha=0.5)
23   nx.draw_networkx_edges(G, pos, arrowstyle='->', arrowsize=40, edge_color='gray')
24
25   # Dibujar etiquetas de los nodos
26   nx.draw_networkx_labels(G, pos, font_size=12, font_family='sans-serif', font_weight='bold')
27
28   # Ajustar los margenes de las etiquetas
29   plt.margins(0.2)
30   plt.axis('off') # Quitar ejes
31
32   plt.show()

```

Obteniendo el siguiente grafo:




Figure 1: Red Bayesiana problema de tamaño medio: Aseguradora.

1.2 Algoritmo de D-separación

Las relaciones de independencia condicional se verifica mediante el criterio de separación-D. Para definir este algoritmo es importante distinguir entre tres tipos de nodos de acuerdo a las direcciones de los arcos que inciden en el nodo:

- Nodos de secuencia, cadena causal: $X \rightarrow Y \rightarrow Z$.

- Nodos divergentes, causa común: $X \leftarrow Y \rightarrow Z$.
- Nodos convergentes, efecto común: $X \rightarrow Y \leftarrow Z$.

1.2.1 Separación D

El conjunto de variables A es independiente del conjunto B dado el conjunto C, si no existe trayectoria entre A y B en que:

1. Todos los nodos convergentes están o tienen descendientes en C.
2. Todos los demás nodos están fuera de C.

Implementación Algoritmo D-separación

Se realiza la implementación del algoritmo D-separación, donde para definir cada uno de los casos en la independencia condicional se revisan los casos: efecto común, cadena causal o causa común.

```

1 def is_active_triple(self, X, Y, Z, evidence, directed_edges):
2     #Cadena causal X -> Y -> Z o causa comun X <- Y -> Z
3     if (X in self.get_parents(Y, directed_edges) and Z not in self.get_parents(Y,
4         directed_edges)) or \
5         (Z in self.get_parents(Y, directed_edges) and X not in self.get_parents(Y,
6         directed_edges)):
7         if Y in evidence:
8             return False # Bloqueada- Y pertenece a la evidencia
9         else:
10            return True # Activa- Y no pertenece a la evidencia
11
12    #efecto comun X -> Y <- Z
13    elif X in self.get_parents(Y, directed_edges) and Z in self.get_parents(Y,
14        directed_edges):
15        # Activa - Y o un descendiente pertenece a la evidencia
16        descendants = self.find_descendants(Y, directed_edges)
17        if Y in evidence or any(d in evidence for d in descendants):
18            return True
19        else:
20            return False
21
22    return False # tripleta bloqueada

```

Se coloca el código completo en el repositorio: Tarea 4.

1.2.2 Consultas realizadas. Problema Alarma

```

1 from redes_bayesianas import BayesianNetwork
2
3
4 edges = [
5     ('burglary', 'alarm'),
6     ('earthquake', 'alarm'),
7     ('alarm', 'john_calls'),
8     ('alarm', 'mary_calls')
9 ]
10
11 bn = BayesianNetwork(edges)
12 evidence = {'alarm'}
13
14 #Primera consulta (B,J|A) Es independiente?
15 print(bn.d_separation('burglary', 'john_calls', evidence, edges))
16
17 #Segunda consulta (B,E|A) Es independiente?
18 print(bn.d_separation('burglary', 'earthquake', evidence, edges))
19
20 #Tercera consulta (B,E|A,E) Es independiente
21 evidence = {'alarm', 'earthquake'}
22 print(bn.d_separation('burglary', 'earthquake', evidence, edges))
23

```

Resultados obtenidos:

```
PS C:\Users\Dani -.-\OneDrive\Documentos\PCIC2024\IA\practicas-ia>  
-.-/OneDrive/Documentos/PCIC2024/IA/practicas-ia/Tarea4_bayesiana  
True  
False  
False
```

Figure 2: Consultas realizadas para el algoritmo de D-separación del problema Alarm.

[2]




Figure 1:

1.3 Ejercicios

14.4 Consider the Bayesian network in Figure 14.2.

- If no evidence is observed, are Burglary and Earthquake independent? Prove this from the numerical semantics and from the topological semantics.
- If we observe $\text{Alarm} = \text{true}$, are Burglary and Earthquake independent? Justify your answer by calculating whether the probabilities involved satisfy the definition of conditional independence.

a. Los nodos Burglary y Earthquake son independientes pues se observan en la topología un efecto común sin evidencia de alarma, se puede decir que son independientes. Luego, numéricamente también se puede calcular $P(B, E) = P(B)P(E)$, lo que confirma esta separación.

b. Por otro lado, si existe evidencia de Alarma, no se garantiza independencia desde la topología de la red. Además, numéricamente se obtiene

$$P(B, E | a) = P(B | a) P(E | a)$$

$$\text{Donde } P(B, E | a) = \propto P(a | B, E) P(B, E)$$

$$= \propto \begin{cases} 0.95 \times 0.001 \times 0.002 \\ 0.94 \times 0.001 \times 0.998 \\ 0.29 \times 0.999 \times 0.002 \\ 0.001 \times 0.999 \times 0.998 \end{cases}$$

$$= \propto \begin{cases} 1.9 \times 10^{-6} \\ 9.3812 \times 10^{-4} \\ 5.7992 \times 10^{-4} \\ 9.9700 \times 10^{-4} \end{cases}$$

para $B=b$ y $E=e$
 para $B=b$ y $E=\neg e$
 para $B=\neg b$ y $E=e$
 para $B=\neg b$ y $E=\neg e$

$$P(B)P(E) = (0.001)(0.002) = 2 \times 10^{-6}$$

$$P(b, e | a) = 1.9 \times 10^{-6} \neq 2 \times 10^{-6} \quad \therefore B \text{ y } E \text{ no son condicionalmente independientes dado } A.$$





Figure 2: Enter Caption

14.8 Consider the network for car diagnosis shown in Figure 14.21.

- Extend the network with the Boolean variables IcyWeather and StarterMotor .
- Give reasonable conditional probability tables for all the nodes.
- How many independent values are contained in the joint probability distribution for eight Boolean nodes, assuming that no conditional independence relations are known to hold among them? *Contiene $2^8 - 1$ variables*
- How many independent probability values do your network tables contain?
- The conditional distribution for Starts could be described as a noisy-AND distribution. Define this family in general and relate it to the noisy-OR distribution.



- d. los valores de probabilidad de los nodos en la red dependen de las relaciones establecidas de los nodos antecedentes.

$$\text{Total de valores} = 2^0 + 2^1 + 2^1 + 2^2 + 2^0 + 2^1 + 2^1 + 2^1 = 15$$

b. Iniciamos con los nodos independientes

Battery

B	P(B)
V	0.84
F	0.16

Gas

G	P(G)
V	0.90
F	0.10

Radio

B	R	P(R B)
V	V	0.75
V	F	0.15
F	V	0.98
F	F	0.02

Ignition

B	I	P(I B)
V	V	0.98
V	F	0.02
F	V	0.001
F	F	0.999

Starts | Ignition, Gas

I	G	S	P(S I,G)
V	V	V	0.97
V	V	F	0.01
V	F	V	0.01
V	F	F	0.01
F	V	V	0.01
F	V	F	0.02
F	F	V	0.01
F	F	F	0.97

Day weather | Starts

S	IW	P(IW S)
V	V	0.80
V	F	0.10
F	V	0.05
F	F	0.95

Starter Motor | Starts

S	SM	P(SM S)
V	V	0.98
V	F	0.02
F	V	0.001
F	F	0.999

Moves | Starter Motor

SM	M	P(M SM)
V	V	0.98
V	F	0.02
F	V	0.0001
F	F	0.9999

e. la tabla de probabilidad condicional para Starts cuenta con ciertas características donde las entradas o son casi cero o en donde todas tienen que ser verdaderas. Esta característica se puede relacionar a la distribución AND y a su vez se puede relacionar con el noisy-OR por leyes de De Morgan $A \wedge B \equiv \neg(\neg A \vee \neg B)$.

$$P(Y = \text{true} | x_1, \dots, x_k) = 1 - \prod_{i: x_i = \text{true}} q_i$$

Donde q_i es la probabilidad de la presencia del i -ésimo padre falle en hacer que el hijo sea verdadero.

y para noisy-AND se tiene

$$P(Y = \text{true} | x_1, \dots, x_k) = \prod_{i: x_i = \text{false}} r_i$$

Donde r_i es la probabilidad de que la ausencia del i -ésimo padre falle en hacer que el hijo sea falso




Figure 3: Enter Caption

14.14 Consider the Bayes net shown in Figure 14.23.

- Which of the following are asserted by the network structure?
 - $P(B, I, M) = P(B)P(I)P(M)$.
 - $P(J | G) = P(J | G, I)$.
 - $P(M | G, B, I) = P(M | G, B, I, J)$.
- Calculate the value of $P(b, i, \neg m, g, j)$
- Calculate the probability that someone goes to jail given that they broke the law, have been indicted, and face a politically motivated prosecutor.
- A context-specific independence (see page 542) allows a variable to be independent of some of its parents given certain values of others. In addition to the usual conditional independences given by the graph structure, what context-specific independences exist in the Bayes net in Figure 14.23?
- Suppose we want to add the variable $P = \text{PresidentialPardon}$ to the network; draw the new network and briefly explain any links you add.

- a) mediante análisis topológico podemos observar la independencia, es decir se cumple el enunciado (i)
- De igual manera la aserción (ii) es verdadera, por análisis topológico, se cumple la independencia condicional.
- (iii) De igual manera se observa por análisis de la topología de la red bayesiana que el nodo M es independiente del resto de los nodos, entonces no influye alguna dependencia condicional (del nodo J en este caso). Es independiente y se cumple la igualdad.

$$b) P(b, i, \neg m, g, j) = P(b)P(\neg m)P(i|b, \neg m)P(g|b, i, \neg m)P(j|g) \\ = 0.9 \times 0.9 \times 0.5 \times 0.8 \times 0.9 = 0.2916$$

c) Dado que B, I, M son valores fijos en la evidencia, se tiene.

$$P(J|b, i, m) = \sum_g P(J, g) = \sum_g [P(J, g) + P(J, \neg g)] \\ = \sum_g [\langle P(j, g), P(\neg j, g) \rangle + \langle P(j, \neg g), P(\neg j, \neg g) \rangle] \\ = \sum_g [(0.81, 0.09) + (0, 0.1)] = [0.81, 0.19]$$


Probabilidad de ir a la cárcel es de 0.81

14.21 Three soccer teams A, B, and C, play each other once. Each match is between two teams, and can be won, drawn, or lost. Each team has a fixed, unknown degree of quality—an integer ranging from 0 to 3—and the outcome of a match depends probabilistically on the difference in quality between the two teams.

- Construct a relational probability model to describe this domain, and suggest numerical values for all the necessary probability distributions.
- Construct the equivalent Bayesian network for the three matches.
- Suppose that in the first two matches A beats B and draws with C. Using an exact inference algorithm of your choice, compute the posterior distribution for the outcome of the third match.
- Suppose there are n teams in the league and we have the results for all but the last match. How does the complexity of predicting the last game vary with n ?
- Investigate the application of MCMC to this problem. How quickly does it converge in practice and how well does it scale?

a) las clases a considerar son los equipos A, B, C tambien el parrafo con instancias AB, BC y CA

b) Teniendo las calidades como variables aleatorias y las salidas a los partidos.



d) la complejidad de predecir estos eventos son de $O(2^n)$ por las calidades de los equipos.

e) El método de las cadenas de monte Carlo podría funcionar si las probabilidades obtenidas no están sesgadas a un equipo.

References

Sucar, L. E. (2024). Redes bayesianas. In (chap. 1). Sta. María Tonantzintla, Puebla, 72840, México.